

GOODLAB 新生考核：大语言模型安全探索

任务背景

大语言模型在开放问答、代码生成、信息检索和智能体系统中已经得到广泛应用。与此同时，模型在恶意诱导、提示词注入、隐私泄露、越狱攻击等场景下也可能暴露安全风险。

本次考核围绕大语言模型安全展开，你需要完成一次小型技术探索：从模型部署出发，理解参数高效微调的基本思想，设计安全相关实验，并通过红队测试分析模型在风险场景下的表现。

我们关注的不是你是否已经熟悉大模型，而是你能否在一个陌生、开放的问题中主动学习、合理拆解、独立实现、记录过程并形成有依据的判断。

任务内容

1. 模型部署

选择一个开源大语言模型，在本地计算机或云服务器上完成部署。

报告中应说明所使用的软硬件环境、模型来源、部署过程、基础推理结果，以及过程中遇到的主要问题和处理方式。

需保留必要的运行证明，例如环境信息、模型加载日志、基础问答结果或相关截图。

2. 安全微调

围绕大语言模型安全问题，选择或构造一个安全相关数据集，并对所部署模型进行 LoRA、QLoRA 或其他参数高效微调。

报告中应说明数据来源、数据构造思路、数据与安全任务之间的关系，以及所采用微调方法的基本原理。

微调实验中应包含至少一组超参数对比。对比内容可围绕学习率、LoRA rank、dropout、训练轮数或其他关键训练设置展开。

实验记录应能够反映不同设置对训练过程或模型行为的影响，而不仅是给出最终结果。

3. 红队测试

围绕微调前后的模型设计红队测试实验，观察模型在安全风险输入下的响应差异。

测试内容、攻击方向、评估标准和指标设计由候选人自行确定。实验应至少比较：

1. 微调前模型；
2. 微调后模型。

如条件允许，可加入更多模型进行横向比较。

红队测试结果应包括测试样本设计、模型输出表现、判定标准、统计结果和典型案例分析。

4. 分析与总结

报告中应重点讨论以下问题：

1. 本任务中“大模型安全”的具体含义；
 2. 所选数据是否真正有助于提升模型安全表现；
 3. 超参数变化对训练过程或模型行为的影响；
 4. 微调后模型是否一定更安全；
 5. 红队测试设计是否充分，以及存在的局限；
 6. 实验过程中出现的关键问题、失败尝试和处理思路。
-

提交内容

最终提交材料包括：

1. 使用 LaTeX 撰写并编译生成的 PDF 报告；
 2. GitHub 仓库链接；
 3. 可复现的代码与运行说明；
 4. 必要的实验日志、结果表格或截图；
 5. 红队测试样例与评估结果。
-

报告要求

报告不要求篇幅很长，但应结构清晰、过程真实、分析具体。

建议包含以下部分：

1. 任务理解；
2. 环境配置与模型部署；
3. 微调方法与实验设计；
4. 红队测试设计；
5. 实验结果与分析；
6. 问题、失败尝试与局限性；
7. 总结。

允许使用公开资料、开源代码和 AI 工具辅助学习与实现，但报告中应如实说明参考来源和使用方式。凡属抄袭、伪造结果或由他人代做的情况，一经发现，直接取消考核资格。